

机器学习概论 大实验

基于多视角声学特征与生成-判别混合模型的语音情感识别研究

文字浩 2023010832 计36

0. 实验概述

本实验在RAVDESS英语语音情感数据集上，采用librosa提取472维话语级多视角声学特征，在说话人无关，即按演员划分训练集和测试集的5折交叉验证下，比较GMM-MAP、核SVM、LightGBM实现的GBDT，与使用以上模型作为基模型，使用线性分类器作为元学习器的Stacking。

主实验以UAR为核心指标，比较各模型的非加权平均召回率。Stacking取得 0.526 ± 0.040 ，95%置信区间约 $[0.499, 0.559]$ ，高于最优单模型RBF-SVM的 0.487 ± 0.063 。跨语料实验在RAVDESS的5类与其他数据集共有的情感子集上，864条音频样本上训练，在CREMA-D的6170条与EMODB的408条样本上测试。UAR降至CREMA-D上的约0.20-0.25与EMODB上的约0.20-0.36，体现明显域偏移。

具体实验过程与运行方法详见 `README.md`

1. 引言与相关工作

语音情感识别SER仅从声学波形推断情感类别，信号连续、高维且受说话人、语种与录音条件影响，是检验特征工程与传统机器学习能力的典型任务。深度学习普及之前，SER常采用ComParE/GeMAPS风格的帧级低层描述符与函数统计聚合作为话语向量，再辅以GMM等生成式模型或SVM/提升树等判别式模型完成训练和预测。

本次实验中，模仿了这种模式，不采用端到端深度网络，而在统一特征与评估框架下比较：生成式模型，每类情感一个GMM，选后验概率最大的做MAP决策；判别式模型，包括多类核SVM、LightGBM；融合模型，Stacking，以三基模型类别概率为输入，线性分类器作为元学习器

相关工作包括INTERSPEECH 2009 ComParE挑战[1]、GeMAPS特征集[2]以及GMM在说话人情感建模中的经典应用[3]。

2. 数据与实验方式

2.1 数据集

数据集	用途	规模	说明
RAVDESS	主实验、跨语料训练	1440条Speech, 24演员, 8类情感	英语
CREMA-D	跨语料测试	6170条Speech, 5类情感子集	英语
EMODB	跨语料测试	408条Speech, 5类情感子集	德语

使用audio模块，在提取feature前做音频统一，采用16kHz采样率、单声道、峰值归一化，具体配置可见 `configs/default.yaml`

2.2 主实验

主实验在RAVDESS数据集上，做说话人无关的5折交叉验证。

划分： `GroupKFold(n_splits=5)`，按 `actor_id` 分组，保证同一演员只出现在训练或测试一侧；类别：8类，包括angry, calm, disgust, fearful, happy, neutral, sad, surprised；样本量：1440 条，特征维度472；指标：UAR无权重平均召回率作为主指标，同时也计算Accuracy, Macro-F1, 5折UAR的均值±标准差，Bootstrap 95% 置信区间（`bootstrap_n=1000`）。

2.3 跨语料实验

跨语料实验，提取三个数据集共有的情感划分子集，在RAVDESS数据集子集上训练，在CREMA-D与EMODB数据集子集上分别做预测。

训练：RAVDESS中属于5类子集的全部样本共864条，共同情感类别为angry, happy, sad, neutral, fearful，去掉了calm、disgust、surprised；测试：CREMA-D与EMODB上同样5类；实验方法：在训练集上一次性拟合模型，在外集上zero-shot预测，无目标域微调

3. 特征提取方法

使用多视角声学特征，通过librosa库加载和处理数据集中的wav音频文件，并提取特征向量，共472维，做8个函数聚合之前为59维，提取方式如下：

1. 读 `configs/default.yaml` 中的 `features.frame_length_ms/hop_length_ms` 帧参数，窗长度为25ms，步长为10ms，将音频拆分为帧。
2. 每一帧提取59维特征向量，包括13维MFCC提取音色特征，一阶 Δ MFCC提取帧间变化，二阶 $\Delta\Delta$ MFCC提取变化的变化，以及20维音质、韵律描述特征，包括F0基频、能量、过零率、谱质心、滚降、带宽、HNR、jitter、shimmer等特征描述，合计59维。
3. 使用八种函数统计做聚合，对全部帧的59维特征向量，每维上计算8种函数统计mean, std, min, max, skew, kurtosis, 25分位数, 75分位数，得到每个音频样本472维特征向量。

实现方法位于 `src/features/frame.py`、`aggregate.py`、`extract.py`，特征向量批量缓存于 `outputs/features/{ravdess,crema_d,emodb}.npz`

4. 模型方法

单条音频特征为 $\mathbf{x} \in \mathbb{R}^{472}$ ，情感标签为 $y \in \mathcal{Y}$ 。主实验中 $|\mathcal{Y}| = 8$ ；跨语料实验中 $|\mathcal{Y}| = 5$ 。5折交叉验证的每一折仅在训练演员上拟合fit，在测试演员上预测predict，避免信息泄漏。

各模型训练前对特征做z-score标准化，在训练集上估计均值 μ 与标准差 σ

$$\tilde{\mathbf{x}} = \frac{\mathbf{x} - \mu}{\sigma + \epsilon}.$$

实现上，GMM在 `train_gmm.py` / `train_stacking.py` 中手动 `fit_transform`；SVM与GBDT将 `StandardScaler` 放入 `sklearn.pipeline.Pipeline`，保证与网格搜索同一流程。

4.1 GMM-MAP

1.模型假设

对每个情感类 $c \in \mathcal{Y}$ ，用相互独立的高斯混合模型GMM刻画类条件分布 $p(\mathbf{x} | y = c)$ 。设混合分量数为 K ，则

$$p(\mathbf{x} | y = c) = \sum_{k=1}^K \pi_{c,k} \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_{c,k}, \boldsymbol{\Sigma}_{c,k}), \quad \sum_{k=1}^K \pi_{c,k} = 1, \pi_{c,k} \geq 0.$$

本实验取对角协方差，即 $\boldsymbol{\Sigma}_{c,k} = \text{diag}(\sigma_{c,k,1}^2, \dots, \sigma_{c,k,d}^2)$ ，共 $d = 472$ 维。对角假设降低参数量、缓解高维下协方差估计不稳定，但牺牲特征间相关性建模能力。

类先验来自训练集相对频数：

$$\pi_c = P(y = c) \approx \frac{N_c}{N}, \quad \log \pi_c \text{ 存入 } \text{log_priors_}.$$

对应 `GMMAPClassifier.fit` (`src/models/gmm_map.py`)，对每个标签 `label` 取子集 `x_c` 拟合 `sklearn.mixture.GaussianMixture`。

2.参数估计

每个类内GMM的参数 $\{\pi_{c,k}, \boldsymbol{\mu}_{c,k}, \boldsymbol{\Sigma}_{c,k}\}$ 通过EM算法极大化对数似然 $\sum_i \log p(\mathbf{x}_i | y = c)$ 迭代求得 (`max_iter=200`, `tol=10^{-4}`, `reg_covar=10^{-6}` 防止协方差奇异)。EM的E步计算样本对各分量的责任度，M步更新混合权重、均值与方差，详见sklearn文档。

3.MAP 决策

对测试样本 $\mathbf{x}$ ，最大后验MAP分类为

$$\hat{y} = \arg \max_{c \in \mathcal{Y}} \log p(\mathbf{x} | y = c) + \log \pi_c.$$

代码中 `log_posteriors` 对每类计算 `gmm.score_samples(x)` (即 $\log p(\mathbf{x} | y = c)$)，再加 `log_priors_[label]`，最后 `argmax` 得 `predict`。

4.2 Kernal SVM

1.模型假设

SVM直接学习判别边界。`sklearn.svm.SVC` 对多类问题为每个类别训练一个二分类器，预测时综合各决策函数或概率。训练目标为在特征空间最大化间隔，对软间隔SVM，引入松弛变量与惩罚系数 C ，在间隔大小与训练误差之间折中。

本实验设置 `class_weight="balanced"`，按类频倒数加权，缓解 8 类样本不平衡。

2.核函数

经标准化后的特征记为 $\tilde{\mathbf{x}}$ ，三种核为：

linear线性核：

$$K(\tilde{\mathbf{x}}_i, \tilde{\mathbf{x}}_j) = \tilde{\mathbf{x}}_i^\top \tilde{\mathbf{x}}_j.$$

rbf径向基核：

$$K(\tilde{\mathbf{x}}_i, \tilde{\mathbf{x}}_j) = \exp(-\gamma \|\tilde{\mathbf{x}}_i - \tilde{\mathbf{x}}_j\|^2),$$

poly多项式核：

$$K(\tilde{\mathbf{x}}_i, \tilde{\mathbf{x}}_j) = (\gamma \tilde{\mathbf{x}}_i^\top \tilde{\mathbf{x}}_j + r)^d, \quad d \in \{2, 3\}.$$

3.超参网格搜索

在当前训练折上，用 `GridSearchCV` + `StratifiedKFold(n_splits=3)` 搜索 `C`、`γ` 及 `poly` 的 `degree`，优化目标为非加权平均召回UAR。折内搜索仅使用训练演员，测试演员不参与调参。

`probability=True` 启用Platt缩放后的类别概率，供Stacking的 `predict_proba` 使用。

4.3 LightGBM GBDT

1.加法模型

梯度提升决策树GBDT将 M 棵回归树串联，以加法方式逐步减小损失。对多类分类，设 $F^{(m)}(\mathbf{x})$ 为第 m 轮累计的 logits，学习率 η ，则

$$F^{(m)}(\mathbf{x}) = F^{(m-1)}(\mathbf{x}) + \eta \cdot h_m(\mathbf{x}),$$

其中 h_m 为拟合当前负梯度的回归树。预测类别取logits最大类，或通过softmax得到类别概率。

2.本实验配置

使用LightGBM的 `LGBMClassifier`

超参数	取值	含义
<code>n_estimators</code>	400	树棵数
<code>max_depth</code>	5	单棵树最大深度
<code>learning_rate</code>	0.1	收缩步长 η
<code>objective</code>	multiclass	多类交叉熵损失
<code>class_weight</code>	balanced	类不平衡加权

LightGBM在叶子生长策略、直方图加速等方面与经典GBDT实现不同，但同属梯度提升树。

`train_gbdtd.py` 在5折交叉验证上评估并输出 `feature_importances_`，统计特征维度的重要程度。

4.4 Stacking 融合

GMM、SVM、GBDT的归纳偏置不同，GMM建模类内分布，SVM找最大间隔边界，GBDT拟合分段非线性。Stacking在第二层用线性分类器学习如何加权组合三者的类别概率，而非手工平均投票。

1.基模型

设全局类别顺序为 $\mathcal{Y} = \{c_1, \dots, c_C\}$ ， $C = 8$ 。对样本 i ，记第 b 个基模型给出的类别概率向量为 $\mathbf{p}_i^{(b)} \in \mathbb{R}^C$ 。对齐到统一类顺序后，拼接得

$$\mathbf{z}_i = [\mathbf{p}_i^{(1)\top}, \mathbf{p}_i^{(2)\top}, \mathbf{p}_i^{(3)\top}]^\top \in \mathbb{R}^{3C}.$$

主实验中 $3C = 24$ 。三基模型为GMM-MAP、RBF-SVM、GBDT。

2.元学习器

元学习器为L2正则多类逻辑回归。对类别 c ，线性得分

$$s_c(\mathbf{z}) = \mathbf{w}_c^\top \mathbf{z} + b_c,$$

经softmax得

$$P(y = c \mid \mathbf{z}) = \frac{\exp(s_c(\mathbf{z}))}{\sum_{c' \in \mathcal{Y}} \exp(s_{c'}(\mathbf{z}))}.$$

训练最小化带L2惩罚的交叉熵。

5. 主实验结果

主实验在RAVDESS数据集上，做说话人无关的5折交叉验证。

5.1 模型对比

模型	UAR	95% CI
GMM-MAP	0.257 ± 0.064	[0.198, 0.299]
SVM linear	0.483 ± 0.046	—
SVM RBF	0.487 ± 0.063	—
SVM poly	0.406 ± 0.045	—
LightGBM	0.482 ± 0.045	[0.447, 0.517]
Stacking	0.526 ± 0.040	[0.499, 0.559]


5.2 各折UAR

Fold	GMM	RBF SVM	GBDT	Stacking
0	0.287	0.509	0.494	0.500
1	0.312	0.406	0.416	0.516
2	0.291	0.578	0.541	0.591
3	0.153	0.475	0.478	0.491
4	0.242	0.465	0.480	0.531

Stacking在fold2达到最高0.591，fold3上GMM仅0.153，说明演员差异与类分布对生成式模型影响较大。

5.3 GBDT特征重要性

LightGBM在5折交叉验证上的分裂增益gain经折间平均后得到特征重要性，472维特征排列方式为：第 j 维对应第 $j/8$ 个帧级的第 $j \bmod 8$ 种函数统计mean / std / min / max / skew / kurtosis / p25 / p75。



排名	特征维	含义
1	f4	MFCC, 偏度
2	f406	局部jitter, p25
3	f423	谐波能量, p75
4	f105	Δ MFCC, 标准差
5	f371	谱带宽, 最大值

6. 跨语料实验结果

跨语料实验训练集为RAVDESS子集，5类情感、864条；测试集为CREMA-D子集6170条、EMODB子集408条。

6.1 CREMA-D测试

模型	UAR	Accuracy
GMM-MAP	0.204	0.210
SVM (RBF)	0.200	0.206
LightGBM	0.249	0.256

6.2 EMODB测试

模型	UAR	Accuracy
GMM-MAP	0.207	0.174
SVM (RBF)	0.203	0.172
LightGBM	0.359	0.373

7. 实验结论

7.1 主实验

1. 判别式明显优于生成式，GMM MAP的UAR仅约0.26，RBF SVM与LightGBM均在0.48左右，说明在472维手工实现的特征下，对角GMM难以刻画类内分布，直接学决策边界更合适。
2. 单模型最优为rbf SVM，UAR为0.487，略优于linear与GBDT，poly SNM最差，为0.406，高维下可能发生欠拟合或不适配。GBDT 特征重要性 (§5.3) 显示增益较高的维度分布在 MFCC 与 jitter、谐波能量、谱结构等韵律/音质统计上，与其 UAR 接近 SVM 的表现相一致。
3. Stacking的UAR为0.526，较RBF SVM提升约4个百分点，三基模型概率经线性元学习器融合有效。同时各折差异较大，Stacking在fold2达 0.591，GMM在fold3仅0.153，说明演员与类分布对结果影响显著。

7.2 跨语料

CREMA-D、EMODB上UAR普遍远低于主实验同语料结果,CREMA-D上多数模型约0.20，接近5类随机猜测，说明无域适配时迁移几乎失效。EMODB上LightGBM相对最好，UAR为0.36，但仍远低于源域。

7.3 局限与期望

特征为librosa手工统计量，未使用预训练音频模型；GMM仅对角协方差，Stacking训练开销较大。后续可考虑深度表征特征；可以考虑使用更加高级的RNN，Transformer等深度学习模型。

参考文献

- [1] Schuller B, Steidl S, Batliner A. The INTERSPEECH 2009 Emotion Challenge. *INTERSPEECH* 2009: 312–315.
- [2] Eyben F, Scherer K R, Schuller B, et al. The Geneva Minimalistic Acoustic Parameter Set (GeMAPS) for Voice Research and Affective Computing. *IEEE Transactions on Affective Computing*, 2016, 7(2): 190–202.
- [3] Reynolds D A, Rose R C. Robust Text-Independent Speaker Identification Using Gaussian Mixture Speaker Models. *IEEE Transactions on Speech and Audio Processing*, 1995, 3(1): 72–83.